

4DEV4RI – Projet

Le cancer du sein

R. Absil, J. Dekeyser, T. Nicodeme, D. Papadimitriou, N. Vansteenkiste

Année académique 2025 - 2026

Résumé

Ce document détaille l'énoncé de votre projet de 4DEV4RI, où l'on vous demande d'utiliser diverses techniques d'apprentissage automatique (*machine learning*) pour déduire des informations pertinentes de données relatives au cancer du sein.

Table des matières

1	Introduction	2
2	Le cancer du sein chez la femme	2
3	Le jeu de données	4
4	Apprentissage automatique	5
4.1	Apprentissage supervisé	5
4.2	Apprentissage non supervisé	6
5	Exploration de données ou apprentissage automatique	6
6	Modalités de remise	7
	Références	8

1 Introduction

Le cancer du sein est l'un des cancers les plus fréquents dans le monde. Il constitue une cause majeure de mortalité liée au cancer chez les femmes. Il survient lorsque des cellules du sein commencent à se développer de manière incontrôlée, formant une tumeur maligne susceptible d'envahir les tissus voisins ou de se propager à d'autres parties du corps.

Le dépistage précoce et un pronostic précis sont cruciaux, car les résultats des traitements dépendent fortement du stade de la maladie au moment du diagnostic ainsi que des caractéristiques biologiques de la tumeur. La pratique clinique moderne repose sur un large éventail d'attributs des patientes et de mesures tumorales, tels que l'ethnie de la patiente, la taille de la tumeur, l'atteinte des ganglions lymphatiques, le grade histologique¹ et le statut des récepteurs hormonaux.

L'objectif de ce projet est de *miner* un jeu de données relatives au cancer du sein, à savoir « en déduire toute information pertinente ». En particulier, on peut :

- entraîner un algorithme de classification (*classifier*) afin de prédire si une patiente va survivre ou non ;
- entraîner un modèle afin d'estimer l'espérance de vie d'un patiente ;
- déterminer quels sont les critères dominants qui influencent la survie d'une patiente ;
- déterminer quels regroupements de patientes peut-on faire pour établir des profils.

Notez que les consignes de ce projet sont délibérément vagues : les objectifs à atteindre sont sommairement présentés, *pas* la manière de les atteindre. C'est à vous de prendre des initiatives, de faire des choix pertinents, de les défendre et d'en assumer la responsabilité.

2 Le cancer du sein chez la femme

Le cancer du sein est une forme de cancer de la glande mammaire, affectant essentiellement les femmes. On s'attend à ce qu'une femme sur huit soit diagnostiquée pour un cancer du sein au cours de sa vie².

Les cellules cancéreuses du sein prennent naissance à l'intérieur des canaux galactophores et/ou des lobules producteurs de lait du sein. La forme la plus précoce (*in situ*) n'est pas mortelle et peut être détectée à un stade précoce. Les cellules cancéreuses peuvent se propager aux tissus mammaires voisins (invasion), ce qui entraîne la formation de tumeurs provoquant des masses ou un épaississement des tissus.

Les cancers invasifs peuvent se propager : on parle de *métastases*. Quand un cancer se propage en métastases, les premières cellules affectées en dehors de la tumeur elle-même sont souvent les ganglions lymphatiques régionaux (ceux qui se trouvent à proximité de la tumeur), responsables de la prolifération et de la différenciation des cellules immunitaires. Les métastases peuvent également affecter d'autres organes.

1. Mesure du progrès de la tumeur, https://fr.wikipedia.org/wiki/Grade_histologique – Dernier accès le 1^{er} mars 2026.

2. <https://www.who.int/news-room/fact-sheets/detail/breast-cancer> – Dernier accès le 1^{er} mars 2026.

Les métastases peuvent engager le pronostic vital et être fatales.

Le traitement dépend de la personne, du type de cancer et de l'extension de celui-ci. Il combine généralement la chirurgie, la radiothérapie et des traitements médicamenteux.

Pour décrire la maladie et orienter les décisions thérapeutiques, les cliniciens s'appuient sur un ensemble d'attributs cliniques et pathologiques standardisés. Ces attributs permettent de caractériser à la fois les propriétés physiques de la tumeur et l'étendue de la progression du cancer dans l'organisme.

En particulier, on classe l'état d'avancement des cancers du sein — appelé *stade* — de la manière suivante :

- le système TNM caractérise l'étendue du cancer :
 - T (tumeur) est utilisé pour décrire la taille de la tumeur primaire et l'envahissement de tissus voisins ;
 - N (lymph node) est utilisé pour décrire la contamination des ganglions lymphatiques régionaux ;
 - M (métastase) est utilisé pour décrire la contamination d'autres organes par le cancer ;
- le système TNM est divisé en sous-catégories :
 - T1, T1, T2, T4 décrivent l'état d'avancement du cancer, T1 étant la forme la plus précoce et T4 étant la plus grave ;
 - N0, N1, N2, N3 et N4 décrivent le degré de contamination des ganglions lymphatiques régionaux : aucun n'est contaminé en N0, plus de 10 pour N4 ;
- les informations du système TNM sont souvent regroupées dans une nomenclature unique, *Adjusted AJCC 6th ed.*³, souvent noté I, II, III et IV, avec des sous-catégories telles que IIA, IIIC, etc. ;
- un système de classification plus large, *A stage*, groupe les cas en trois grandes catégories :
 - localisé, quand la tumeur est confinée dans le sein ;
 - régionale, quand la tumeur s'est étendue aux ganglions lymphatiques régionaux ;
 - distant, quand la tumeur a métastasé dans des organes distants.

En plus du stade, les cliniciens caractérisent également le comportement histologique⁴ de la tumeur :

- le grade (1, 2, 3, 4) et la différenciation décrivent à quel point les cellules tumorales ressemblent à des cellules saines sous un microscope, ce qui est une caractéristique d'agressivité de la tumeur : des cellules de grade 1 sont bien différenciées et dénotent souvent un cancer à l'expansion lente, contrairement, par exemple, au grade 3 dénotant des cellules peu différenciées ;
- l'état des récepteurs hormonaux décrit si la croissance de la tumeur est sensible à des facteurs hormonaux, classiquement les œstrogènes et la progestérone ;
- la taille de la tumeur, ainsi que le nombre de ganglions examinés et contaminés sont utilisées quantitativement pour caractériser la progression de la maladie.

Notez que vous vous placez dans le contexte d'un projet de *machine learning* pour des *informaticiens*. Vous n'êtes *pas* des médecins :

3. <https://seer.cancer.gov/seerstat/variables/seer/ajcc-stage/6th/> – Dernier accès le 1^{er} mars 2026.

4. L'histologie [...] est la branche de la biologie et de la médecine qui étudie les tissus biologiques, <https://fr.wikipedia.org/wiki/Histologie> – Dernier accès le 1^{er} mars 2026.

1. vous ne comprenez (très certainement) pas finement le fonctionnement du cancer du sein, et vous n'avez pas *besoin* de le comprendre, c'est d'ailleurs pour cette raison que vous utilisez du *machine learning* ;
2. même si vous concevez un excellent modèle de prédiction, ne le sortez pas de son contexte, et en particulier ne l'utilisez pas à vertu de diagnostic réel.

3 Le jeu de données

Ce jeu de données de patientes atteintes d'un cancer du sein provient de la mise à jour de novembre 2017 du programme SEER⁵ du NCI⁶, qui fournit des informations issues de statistiques de cancer basées sur la population. Le jeu de données concerne des patientes atteintes d'un cancer du sein de type carcinome canalaire⁷ infiltrant et lobulaire (codes histologiques NOS « SEER primary sites recode » 8522/3), diagnostiquées entre 2006 et 2010.

Les patientes présentant une taille de tumeur inconnue, un nombre de ganglions lymphatiques régionaux examinés inconnu, un nombre de ganglions lymphatiques régionaux positifs inconnu, ainsi que celles dont la survie était inférieure à un mois en ont été exclues. Au total, 4 024 patientes ont été retenues.

Le jeu de données vous est fourni, au format `csv`, dans le fichier `resource/train.csv`. Il comporte 16 attributs.

1. *Id* : un identifiant unique (arbitraire) par patiente.
2. *Race* : l'ethnie de la patiente.
3. *Marital Status* : l'état civil de la patiente.
4. *T Stage* : stade T du cancer, tel que décrit par le système TNM.
5. *N Stage* : stade N du cancer, tel que décrit par le système TNM.
6. *6th Stage* : le stade du cancer, tel que décrit par l'*AJCC 6th stage*.
7. *Differentiate* : la différenciation des cellules cancéreuses.
8. *Grade* : le grade des cellules cancéreuses.
9. *A Stage* : le stade du cancer, tel que décrit par le système *A stage*.
10. *Tumor Size* : la taille de la tumeur, en millimètres.
11. *Estrogen Status* : décrit si les cellules cancéreuses ont ses récepteurs hormonaux sensibles aux œstrogènes.
12. *Progesterone Status* : décrit si les cellules cancéreuses ont ses récepteurs hormonaux sensibles à la progestérone.
13. *Regional Node Examined* : le nombre de ganglions lymphatiques régionaux retirés chirurgicalement et examinés au microscope.
14. *Regional Node Positive* : le nombre de ganglions lymphatiques régionaux retirés chirurgicalement et caractérisés comme contaminés.
15. *Survival Months* : l'espérance de vie estimée de la patiente au moment du diagnostic, en mois.

5. <https://seer.cancer.gov/about/> – Dernier accès le 1^{er} mars 2026.

6. <https://www.cancer.gov/> – Dernier accès le 1^{er} mars 2026.

7. Il existe plusieurs types de cancer du sein. Celui-ci est le plus courant.

16. *Status* : la patiente est-elle décédée des suites de son cancer du sein.

On remarque que ce jeu de données est *a priori* prévu pour de l'apprentissage supervisé : les données sont étiquetées, et vous savez si une patiente a survécu (parce que cette information est fournie). On l'utilisera néanmoins également dans un contexte d'apprentissage *non* supervisé.

Finalement, comme pour tout problème d'entraînement d'un modèle, il faut partitionner le jeu de données en entrée en trois ensembles : l'ensemble d'entraînement, l'ensemble de validation (facultatif) et l'ensemble de test. Ce travail n'est pas fait pour vous : vous devez le faire *vous-même* pour chacun des modèles que vous choisissez d'entraîner.

4 Apprentissage automatique

Cette section détaille le travail d'apprentissage automatique (*machine learning*) qui est attendu de vous pour votre projet. Notez que les instructions données ici sont délibérément vagues : c'est à vous de prendre les bonnes décisions, de tester plusieurs approches, de les comparer, de tirer vos conclusions et de les défendre.

- À ce titre, nous vous recommandons de lire attentivement deux annexes de l'UE 4ALG4A :
- l'annexe 3, qui liste les erreurs courantes (en intelligence artificielle et *design* d'agents) à ne pas commettre et les alternatives pour les éviter;
 - l'annexe 4, qui liste différentes formes de pré-traitement (*preprocessing*) de données qui sont souvent nécessaires avant de soumettre des données à l'entraînement d'un modèle.

4.1 Apprentissage supervisé

Le jeu de données du cancer du sein est étiqueté : les attributs ont un nom, et on veut classiquement prédire l'espérance de vie et la survie d'une patiente. Il est donc naturel d'utiliser des techniques d'apprentissage supervisé (*supervised learning*).

En l'occurrence, nous vous demandons d'entraîner des modèles prédictifs capables de déterminer si une patiente va survivre ou non⁸, et d'en comparer analytiquement les performances. Il est également attendu que vous prédisiez l'espérance de vie d'une patiente⁹.

Vous devez *au minimum* produire 3 modèles :

- au moins un arbre de décision ;
- au moins un modèle de régression (linéaire ou non) ;
- au moins un « autre » modèle qui sera utilisé pour faire de la classification et de la régression¹⁰. Vous pouvez par exemple employer de la régression logistique¹¹ [3], des machines à vecteurs de support¹² [3] ou des réseaux neuronaux¹³ [2].

8. On vous demande donc de faire de la *classification*.

9. On vous demande donc de faire de la *régression*.

10. Vous devrez donc choisir un modèle capable d'effectuer ces deux tâches, et faire l'entraînement deux fois.

11. https://en.wikipedia.org/wiki/Logistic_regression – Dernier accès le 1^{er} mars 2026.

12. https://en.wikipedia.org/wiki/Support_vector_machine – Dernier accès le 1^{er} mars 2026.

13. [https://en.wikipedia.org/wiki/Neural_network_\(machine_learning\)](https://en.wikipedia.org/wiki/Neural_network_(machine_learning)) – Dernier accès le 1^{er} mars 2026.

4.2 Apprentissage non supervisé

Bien que le jeu de données du cancer du sein soit étiqueté, on peut également utiliser des techniques d'apprentissage non supervisé (*unsupervised learning*) pour détecter des similarités dans les données et regrouper les patientes en différents groupes aux caractéristiques similaires.

En l'occurrence, nous vous demandons d'entraîner divers modèles de partitionnement (*clustering*) sur ce jeu de données, et d'en analyser la qualité. Vous êtes libres d'utiliser d'autres formes d'apprentissage non supervisé, tel que la détection de règles d'association.

Vous devez *au minimum* produire deux modèles :

- au moins un modèle de clustering entraîné par l'algorithme k-means et variantes (McQueen, Hartigan et Wong, k-means++) ;
- au moins un modèle de clustering entraîné hiérarchiquement ¹⁴ [1].

5 Exploration de données ou apprentissage automatique

La section 4 sous suggère d'utiliser divers outils afin de construire des *modèles prédictifs*. C'est l'un des objectifs principaux du *machine learning* : utiliser des algorithmes pour faire des *prédictions*.

L'objectif de ce projet *n'est pas* la prédiction, mais l'exploration de données (*data mining*) : utiliser des techniques pour *déduire des informations pertinentes d'un jeu de données*.

Souvent, les techniques du *data mining* sont des algorithmes de *machine learning*.

Par exemple :

- on utilise un arbre de décision pour prédire si une patiente survit : c'est du *machine learning* ;
- on utilise un arbre de décision pour déduire que le principal facteur qui influe sur la survie d'une patiente est le stade tumoral : c'est du *data mining* ;
- on utilise un algorithme de *clustering* pour partitionner les patientes en groupes aux caractéristiques similaires : c'est du *machine learning* ;
- on remarque que le plus grand *cluster* est composé des femmes avec un cancer précoce, qui ont de bonnes chances d'avoir survécu : c'est du *data mining*.

Donc, bien que vous allez utiliser des algorithmes de *machine learning* pour construire des modèles, la finalité de ces modèles *doit* être la déduction d'informations. Vous devrez établir vos conclusions en ce sens.

14. https://en.wikipedia.org/wiki/Hierarchical_clustering – Dernier accès le 1^{er} mars 2026.

6 Modalités de remise

En ce qui concerne les algorithmes de classification et de régression que vous avez utilisés pendant l'entraînement, vous devez faire valider vos modèles auprès du service web :

<https://jdekeyser-he2b.alwaysdata.net>.

Voici ce qui est effectivement attendu de vous :

- Vous devez soumettre le fichier **resource/eval.csv** à chacun de vos modèles de classification et de régression. Ce fichier a le même format que **train.csv**, décrit en section 3, les attributs *Survival Months* et *Status* ne sont toutefois pas inclus.
- Vos modèles doivent produire un fichier **predictions.csv** :
 - il prédit l'espérance de vie et la survie des patientes du fichier **eval.csv** ;
 - il doit comporter le même nombre de lignes que le fichier **eval.csv**, et inclure *exactement* les mêmes identifiants ;
 - il ne doit comporter que trois attributs ;
 - sa première ligne est une ligne d'entête comportant les entrées *Id*, *Survival Months* et *Status* ;
 - chacune de ses autres lignes contient un identifiant de patiente et les valeurs prédites d'espérance de vie et de survie de celle-ci.
- Vous devez soumettre votre fichier **predictions.csv** au service web et récupérer les métriques de « performance » qu'il vous fournit.

Le fichier **naive.csv** est fourni à titre d'exemple de format pour **predictions.csv**. L'espérance de vie prédite est la moyenne des espérances de **train.csv**, et la survie est la classe majoritaire, telle que retournée par *Naive Bayes*.

Vous devez venir le jour de l'évaluation avec le résultat des métriques calculées par le service web.

Vous devez rédiger un rapport au format **ipynb**¹⁵, **md**¹⁶ ou PDF qui détaille :

- vos « conclusions *data mining* » ;
- les métriques de performance et de qualité de vos modèles¹⁷ ;
- les comparaisons que vous avez effectuées entre vos modèles, et les raisons pour lesquelles certains de vos modèles ont de moins bonnes performances que d'autres.

Vous devez soumettre l'intégralité de votre travail (code et rapport) via un dépôt git créé pour vous. Son URL HTTPS est de la forme :

<https://git.esi-bru.be/2025-2026/4dev4ri/XXXX/4dev4ri-YYYYY-2026>,

où

- XXXX est à remplacer par l'identifiant de votre groupe, par exemple, « C311 »,
- YYYYY est à remplacer par votre matricule, par exemple « 12345 ».

15. <https://jupyter.org/#jupyter-notebook-the-classic-notebook-interface> – Dernier accès le 12 mars 2026.

16. <https://www.markdownguide.org/> – Dernier accès le 12 mars 2026.

17. Ceci inclut notamment les métriques de classification, régression et clustering sur les fichiers **train.csv** et **eval.csv** et celles calculées par le service web.

Placez :

- un fichier `.gitignore` adéquat ;
- votre code dans un répertoire `src` ;
- votre rapport dans un répertoire `doc` ;

tous les trois situés à la racine de votre dépôt.

La *deadline* de soumission est fixée au 15 mai 2026 à 18h. Aucun retard ne sera toléré.

Renseignez-vous auprès de votre maître-assistant quant à ses exigences propres qui pourraient s'ajouter à celles décrites dans le présent document.

Références

- [1] C. C. Aggarwal and C. K. Reddy. *Data Clustering : Algorithms and Applications*. Chapman & Hall, 2013. <https://people.cs.vt.edu/~reddy/papers/DCBOOK.pdf>.
- [2] I. Goodfellow, Y. Bengio, and A. Courville. *Deep learning*. The MIT Press, 2016. <http://www.deeplearningbook.org>.
- [3] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor. *An introduction to statistical learning, with applications in Python*. Springer, 2023. <https://www.statlearning.com/>.

Les références bibliographiques accompagnées d'une URL¹⁸ sont disponibles légalement en ligne.

18. Derniers accès le 12 mars 2026.